

Relatório Técnico — D&O Shield

Plataforma Inteligente para Análise e Comparação de Apólices D&O Projeto Final — InsurMinds

· Instituto de Inteligência Artificial Aplicada (I2A2)

Grupo: InsurAi — Juan David Valle Sánchez, Rodrigo Silva Figueiredo, Isabela Del Rio, Karin Abe

Data: 06/10/2026 Repositório: <https://github.com/abe-karin/seguro-insurai> Licença: MIT

1. Resumo executivo

Apólices e condições gerais de seguro D&O (Directors & Officers) são documentos longos, de linguagem jurídica, e compará-los exige horas de um especialista. O **D&O Shield** é um protótipo funcional que automatiza esse trabalho com IA Generativa: recebe os documentos (PDF ou imagem), extrai o texto, estrutura uma **ficha técnica D&O de 22 tópicos**, armazena os dados, permite **consultas em linguagem natural** e **compara de duas a três apólices**, apresentando as diferenças por relevância.

O princípio de projeto é a **rastreabilidade**: toda informação extraída cita a **página** e o **trecho literal** do documento, e o sistema confere se o trecho de fato existe naquela página. Em vez de pedir ao usuário que confie no modelo, a plataforma permite que ele confira.


2. Problema e escopo

Dificuldade	Como a plataforma responde
Documentos de 50 a 100+ páginas	Leitura página a página, lotes em paralelo, fusão sem duplicatas
Estruturas diferentes entre seguradoras	Ficha técnica com os mesmos 22 tópicos para todos os documentos, o que torna as respostas comparáveis
Risco de o modelo inventar informação	Cada item cita página e trecho; verificação automática do trecho (✅ / ⚠️)
Decidir o que importa nas diferenças	Análise por LLM: relevância (alta/média/baixa), apólice mais favorável e recomendação
Achar uma cláusula no meio do documento	Consulta em linguagem natural com resposta citando a página

Fora do escopo (conforme o enunciado): produto comercial, alta disponibilidade, integração com sistemas de seguradoras e cobertura de todos os tipos de apólice. A comparação avalia

condições contratuais, não preço.

3. Arquitetura



Os agentes são módulos Python independentes, cada um com uma responsabilidade, que se comunicam por objetos Pydantic. Isso permite testar cada etapa isoladamente (sem rede) e trocar uma peça (por exemplo, o provedor de LLM) sem tocar nas demais.

4. Agentes

4.1 Agente de Ingestão (`agents/ingestion\_agent.py`)

Extraí o texto **por página**. Estratégia em camadas: `pdfplumber` (padrão) → `PyMuPDF` se vier pouco texto → **OCR Tesseract** se o PDF for digitalizado; imagens (PNG, JPG, TIFF) vão direto ao Tesseract (português + inglês). Localiza o binário do Tesseract automaticamente (variável

`TESSERACT\_CMD`, PATH e caminhos do Windows) e usa `storage/tessdata` quando existir. Falhas geram mensagens com instruções de correção.

4.2 Agente de Extração (`agents/extraction\_agent.py`)

Envia o texto, com marcadores `[[PÁGINA n]]`, a um LLM com **saída estruturada** (schema Pydantic nativo no Gemini; JSON Schema no prompt para OpenAI/Anthropic). O resultado é pós-processado:

1. **Divisão em lotes** de ~90 mil caracteres, **apenas em fronteiras de página**, processados **em paralelo**;
2. **Fusão** dos lotes sem duplicatas (sem acentos e sem diferença de caixa);
3. **Deduplicação fuzzy de coberturas**: documentos D&O listam as extensões num resumo e depois as detalham; nomes como “Extensão de Cobertura para X” e “Extensão para X” são unidos, mantendo a descrição mais completa;
4. **Ficha completa**: os 22 tópicos sempre presentes (`null` = o documento não trata do assunto); tópicos inventados pelo modelo são descartados;
5. **Verificação de ancoragem**: para cada fonte citada, confere se o trecho aparece na página indicada (tolerando acentos e quebras de linha), corrige erros de uma página e marca o restante como não verificado.

4.3 Agente de Comparação (`agents/comparison\_agent.py`)

Funciona em duas etapas deliberadamente separadas:

1. **Alinhamento determinístico**. Os valores de cada tópico vêm da ficha extraída — o LLM nunca “recita” valores, portanto não pode inventá-los. Calcula quais tópicos divergem.
2. **Julgamento por LLM**. Recebe apenas os tópicos divergentes e devolve a relevância, a apólice mais favorável ao segurado, um comentário prático, o resumo executivo e a recomendação.

Se o LLM falhar, a comparação continua em **modo determinístico**. Aceita de 2 a 3 apólices; para listas (coberturas, exclusões, cláusulas) aponta os itens que aparecem em apenas parte delas.

4.4 Agente de Consulta (`agents/query\_agent.py`)

Recuperação + geração. Um índice **BM25** (sem acentos e sem palavras vazias) escolhe as páginas mais relevantes **de cada apólice** selecionada; o LLM responde somente com esses trechos e a ficha técnica, citando `[apólice, p. N]`. As citações são conferidas contra as páginas realmente recuperadas, descartando referências inventadas.

4.5 Agente de Relatório (`agents/report\_agent.py`)

Gera Markdown e PDF. O PDF é montado direto dos objetos estruturados com a API de tabelas do `fpdf2`; o comparativo sai em paisagem, com uma coluna por apólice.

4.6 Cliente de LLM (`agents/llm\_client.py`)

Camada única usada por todos os agentes: provedores (Gemini, OpenAI, Anthropic), saída validada por Pydantic com uma repetição se o JSON vier inválido, **tempo limite, retentativa** em 429/503/timeouts, **rodízio automático entre modelos** quando um está sobrecarregado ou indisponível, e detecção de resposta truncada. Toda falha vira `LLMError` — nada é engolido em silêncio.

5. Fluxo de processamento

1. O usuário envia um ou mais arquivos (aba **Enviar apólices**).
2. A ingestão devolve o texto de cada página.
3. A extração gera a ficha técnica, as coberturas, as exclusões e as cláusulas, com a fonte de cada item, e verifica as fontes.
4. A apólice e o texto das páginas são gravados no SQLite.
5. **Consultar**: pergunta → BM25 por apólice → LLM responde citando as páginas.
6. **Comparar**: 2 a 3 apólices → alinhamento por tópico → análise do LLM → relatório.
7. O resultado é exibido e pode ser exportado em PDF ou Markdown.

6. Modelo de dados

- `ApoliceExtraida`: dados da apólice e do segurado, `ficha_tecnica` (lista de `ItemFicha`: tópico, valor, `Fonte`), coberturas, exclusões, cláusulas especiais, observações, total de páginas.
- `Fonte`: página, trecho literal e `verificada` (preenchido pelo sistema, não pelo modelo).
- `RelatorioComparativo`: apólices, divergências (`DiferencaTopico`: valores por apólice com página, relevância, comentário, mais favorável), tópicos sem divergência, resumo, recomendação, modo (`Ilm`/`deterministico`) e modelo usado.
- Persistência (SQLite/SQLAlchemy): tabelas `policies`, `policy_pages` (texto de cada página) e `comparisons`.

Ficha técnica D&O (22 tópicos)

Acionamento: base de acionamento, retroatividade, prazo de aviso, prazo complementar de notificação. Coberturas: pessoas seguradas, Side A, Side B, Side C, custos de defesa, multas e penalidades. Limites: limite e sublimites, franquia. Exclusões: dolo, vantagem indevida, poluição, fatos anteriores, reclamações entre segurados. Processo: escolha da defesa, mudança de controle, rateio, cancelamento, arbitragem e foro, território.

7. Tecnologias e justificativas

Tecnologia	Papel	Por que
Python 3.11+	Linguagem	Ecossistema de IA, OCR e dados

Tecnologia	Papel	Por que
Streamlit	Interface web	Demonstração rápida de um MVP, sem front-end separado
Google Gemini (padrão), OpenAI, Anthropic	LLM	Provedor trocável; o Gemini tem contexto longo, saída estruturada nativa e plano gratuito
Pydantic v2	Schemas e validação	Contrato explícito entre agentes; rejeita saída fora do formato
pdfplumber, PyMuPDF, Tesseract	Leitura e OCR	PDFs com texto embutido e digitalizados
BM25 próprio	Recuperação da consulta	Sem serviço extra, explicável, adequado a texto jurídico de terminologia estável
SQLite + SQLAlchemy	Persistência	Zero infraestrutura; troca por outro banco sem alterar os agentes
fpdf2	PDF	Tabelas com quebra automática de texto, sem dependências de sistema

8. Decisões arquiteturais

Resumidas abaixo; o registro completo, com os problemas da primeira versão que motivaram cada mudança, está em ``DECISOES_DE_ARQUITETURA.md``.

- **Ficha técnica com tópicos fixos** para tornar documentos heterogêneos comparáveis.
- **Fonte + verificação** para combater alucinação e permitir auditoria.
- **Lotes por página, em paralelo**, para não cortar frases e reduzir latência.
- **Comparação em duas etapas** (alinhar e depois julgar) para que o LLM não invente valores.
- **BM25 em vez de embeddings** na consulta: simples, rápido e explicável.
- **Cliente de LLM único com rodízio de modelos**, pois a disponibilidade dos modelos oscila (observamos 503 de alta demanda em vários modelos no mesmo dia).
- **Relatórios gerados dos objetos**, não de Markdown, para não perder linhas de tabela.

9. Resultados com documentos reais

Usamos três documentos públicos, registrados na SUSEP, de seguradoras do mercado brasileiro (listados na seção 11).

Documento	Páginas	Caracteres	Coberturas	Exclusões	Fontes verificadas	Tempo
Porto Seguro	52	175.120	34	28	103 de 103	207 s
AXA Seguros	104	230.777	41	25	89 de 89	191 s
Allianz Seguros	75	248.634	—	—	—	em validação

Extração com `gemini-flash-lite-latest`, em lotes paralelos. Todos os 22 tópicos da ficha técnica foram preenchidos nos dois documentos processados, cada um com página e trecho confirmados no texto original. Na Porto, a deduplicação de coberturas reduziu 52 itens brutos para 34: o documento lista as extensões num resumo inicial e as detalha nas cláusulas.

Durante os testes, a API do Gemini apresentou erros 503 (alta demanda) e, sob chamadas simultâneas, 429 (cota do plano gratuito). O rodízio de modelos e as retentativas do cliente de LLM absorveram parte disso, mas o processamento ficou estável apenas com um documento por vez.

10. Testes

`python -m unittest discover -s tests -t .` executa a suíte automatizada de 64 testes (sem rede e sem chave de API), que cobre: divisão e fusão de lotes, deduplicação de coberturas, verificação de ancoragem (trecho literal, inventado, página errada, acentos), comparação determinística e com LLM simulado (relevância inválida, apólice favorável inexistente, falha do LLM, 2 e 3 apólices), consulta (BM25, citações válidas e inventadas), persistência, ingestão e geração dos PDFs — incluindo um **teste de regressão que lê o PDF gerado e confere que as linhas das tabelas estão presentes** (a primeira versão exportava só os cabeçalhos).

11. Fontes dos documentos

Documentos públicos de seguradoras, usados somente para demonstração:

- Porto Seguro — *Condições Gerais, Seguro de Responsabilidade Civil para Administradores (D&O) — Empresas de Capital Fechado*, vigência a partir de 01/02/2022.
- AXA Seguros — *Condições Gerais, Seguro de Responsabilidade Civil de Diretores e Administradores (D&O) — Base de Reclamações com Notificação*, processo SUSEP 15414.901016/2017-01, versão 12/2025.
- Allianz Seguros — *Responsabilidade Civil de Diretores e Administradores de Empresas (D&O)*, processo SUSEP 15414.901113/2017-96, versão 12/2025.

12. Limitações conhecidas

- A qualidade da extração depende do modelo e da qualidade do texto; por isso cada item traz a fonte e o selo de verificação, e a conferência humana continua recomendada.
- A verificação confirma que o **trecho existe** na página, mas não garante que o **resumo** do modelo o interprete corretamente.
- A comparação avalia condições contratuais, não preço, e não substitui parecer de corretor ou jurídico.
- A consulta usa recuperação lexical; perguntas com sinônimos muito distantes do texto podem exigir reformulação.
- A disponibilidade do LLM é externa ao projeto: em dias de alta demanda o processamento de documentos grandes pode levar alguns minutos.
- O banco SQLite local é efêmero em hospedagens como o Streamlit Cloud.
- Tabelas e imagens dentro dos PDFs só são lidas se o texto estiver embutido ou via OCR.

13. Evolução futura

- Recuperação híbrida (BM25 + embeddings) e reordenação dos trechos.
- Verificação semântica do resumo (modelo juiz), além da verificação do trecho.
- Extração de valores monetários e prazos em campos tipados, permitindo comparações numéricas e cálculo de cobertura efetiva.
- Suporte a outros ramos (RC Profissional, Cyber) reaproveitando a arquitetura: basta trocar a lista de tópicos.
- Autenticação, múltiplos usuários, banco gerenciado e trilha de auditoria.
- Painel de portfólio: comparar muitas apólices e destacar lacunas de cobertura.